

Análisis de pertenencia con GMM y HDBSCAN de M41

Santiago Vargas Gómez*
Universidad de los Andes, Bogotá, Colombia.
(Dated: 15/03/2026)

I. INTRODUCCIÓN

La disponibilidad de datos con cada vez más precisión presentados en las misiones GAIA (la más reciente siendo Data Release 3), combinado con el poder de procesamiento actual, ha permitido la caracterización de cúmulos a un nivel de precisión sin antecedente. Históricamente, el problema de pertenencia para cúmulos era resuelto mediante métodos bayesianos (como el modelo de Vasilevskis-Slovak)(Vasilevskis et al., 1958) que con los años se refinaron a algoritmos de partición geométrica (ej. k-means (MacQueen, 1967) o Modelos de Mezcla Gaussiana, GMM) (McLachlan Basford, 1988); sin embargo, como todo modelo, dependían de suposiciones o restricciones a priori sobre la morfología del cúmulo.

Por ejemplo, los GMM asumen matrices de covarianza que imponen sobre los cúmulos geometrías elipsoidales simétricas en el espacio de fases ($\mu_{\alpha*}, \mu_{\delta}, \varpi$). Estos modelos, aunque útiles en su tiempo, no cuentan con la “resolución” suficiente para tener en cuenta complejidades como la rotación diferencial galáctica; la forma elíptica no uniforme en la distribución de velocidades; estructuras coherentes que, aunque no son cúmulos, comparten vectores de velocidad similares; gradientes de extinción y enrojecimiento diferencial debido a las distribuciones no uniformes de polvo estelar; o la consideración de múltiples componentes cinemáticas más allá del cúmulo y el campo.

Con el propósito de reducir el sesgo geométrico, se introdujeron enfoques de densidad al aprendizaje no supervisado. El algoritmo original DBSCAN (Density-Based Spatial Clustering of Applications with Noise) presentó un avance en la agrupación de puntos continuos por encima de un umbral de densidad global (Ester et al., 1996). No obstante, en la realidad, la densidad es dependiente de la altitud galáctica y la distancia del observador, por lo que un umbral de distancia (ϵ) fijo es insuficiente para detectar cúmulos de alta densidad y asociaciones estelares dispersas o de baja densidad.

Para resolver el problema de densidades variables, Campello et al. (2013) introdujeron HDBSCAN (Hierarchical Density-Based Spatial Clustering of Applications with Noise). Esta extensión transforma el problema de un corte de densidad global al análisis de la estabilidad de las agrupaciones estelares entre todas las densidades posibles. En vez de aplicar un corte, el algoritmo crea un mapa de conexiones (árbol) y selecciona los grupos que persisten unidos a través de todas las distancias, permitiendo separar el cúmulo del ruido galáctico de forma adaptable, sin depender de un ϵ rígido y global.

La eficacia de HDBSCAN depende en gran medida de dos hiperparámetros: `min_cluster_size` y `min_samples`.

El hiperparámetro `min_cluster_size` define el tamaño mínimo que debe tener un conjunto de estrellas vecinas para ser considerado un cúmulo. A la hora de analizar M41 un valor muy bajo podría fragmentar un cúmulo “real” en múltiples sub-cúmulos “computacionales” (analizados por el HDBSCAN pero que no son acordes a la realidad). Por otro lado, un valor muy alto en el hiperparámetro `min_cluster_size` podría ignorar el cúmulo por completo ya que algorítmicamente no tiene el suficiente número de estrellas para ser un cúmulo. En el VPD, un `min_cluster_size` relativamente pequeño hará que el VPD esté lleno de ruido visual al haber múltiples sub-regiones; un `min_cluster_size` relativamente grande podría hacer que el cúmulo desaparezca o que solo se distinga una región altamente concentrada, ignorando estrellas periféricas y posibles colas de marea (dependiendo del cúmulo). En el CMD, un `min_cluster_size` relativamente pequeño los miembros no formarán una Secuencia Principal clara; un `min_cluster_size` relativamente grande solo identificará las partes más densas de la Secuencia Principal, haciendo que se vea más definida pero incompleta, ya que se podría perder el Turn-Off o la Rama de Gigantes Rojas debido a la baja concentración de estrellas que es menor al mínimo establecido en el hiperparámetro utilizado por el HDBSCAN. Las ecuaciones implementadas por este algoritmo se presentan en el apéndice de ecuaciones.

De igual importancia, el hiperparámetro `min_samples` determina cuántos vecinos debe tener una estrella para ser considerada parte de un núcleo denso (core point). En el presente laboratorio

* Correo institucional: s.vargas2@uniandes.edu.co

computacional, el `min_samples` puede considerarse la resolución del HDBSCAN ante el ruido. En el VPD, incrementar este hiperparámetro permite hayar el punto más denso del M41 a cambio de perder la dispersión natural del cúmulo y en el CMD al incrementar `min_samples` hará que la secuencia principal se vea más delgada, pero a cambio de perder estrellas que pertenecen a la secuencia, pero que estaban en las regiones menos pobladas del espacio de fase.

II. OBJETIVOS

A. Objetivo General

Determinar la pertenencia cinemática y fotométrica de la población estelar del cúmulo abierto M41 (NGC 2287) a partir del catálogo espacial Gaia DR3, mediante la contrastación algorítmica entre un modelo probabilístico paramétrico tradicional y técnicas avanzadas de aprendizaje topológico no supervisado (HDBSCAN).

B. Objetivos Específicos

1. Preprocesar el espacio de fases astrométrico aplicando un umbral de calidad señal-ruido sobre la paralaje ($PoE > 5$).
2. Implementar un modelo Bayesiano paramétrico (tipo Vasilevskis-Slovak) optimizado mediante el algoritmo L-BFGS-B en el espacio 2D ($\mu_{\alpha*}, \mu_{\delta}$), para la discriminación del cúmulo y el campo galáctico.
3. Evaluar el desempeño del algoritmo de densidad HDBSCAN contrastando su ejecución en espacios espaciocinemáticos de dos (2D) y tres dimensiones (3D, integrando ϖ).
4. Validar físicamente las poblaciones extraídas mediante el análisis morfológico comparativo del Vector Point Diagram (VPD) y la confirmación de pureza de la Secuencia Principal en el Diagrama Color-Magnitud (CMD), apoyándose en visualizaciones de densidad logarítmica (*Hexbin*) para aislar el núcleo del cúmulo frente al ruido de fondo galáctico.

III. MARCO TEÓRICO: PERTENENCIA DE ESTRELLAS EN CÚMULOS ABIERTOS VÍA ASTROML

A. Calidad Astrométrica y la Relación Parallax-Over-Error (PoE)

La precisión de los parámetros derivados en Gaia DR3 depende de la calidad de cinco parámetros $\alpha, \delta, \varpi, \mu_{\alpha*}, \mu_{\delta}$:

- α y δ (**Ascensión Recta y Declinación**): Son las coordenadas indican la posición exacta de la estrella en el cielo (el equivalente a la longitud y latitud en la Tierra).
- $\mu_{\alpha*}$ y μ_{δ} (**Movimientos propios**): Describen cómo y a qué velocidad se desplaza la estrella a través del cielo a lo largo del tiempo.
- ϖ (**Paralaje**): Es el pequeño cambio aparente en la posición de la estrella causado por el movimiento de la Tierra alrededor del Sol, el cual es vital para calcular a qué distancia se encuentra.

En este estudio, se utiliza un filtro de relación señal-ruido centrado en la paralaje, definido como:

$$PoE = \frac{\varpi}{\sigma_{\varpi}} \quad (1)$$

Donde ϖ es la paralaje y σ_{ϖ} su error estándar.

Un umbral $PoE > 5$ asegura que el error relativo en la estimación de la distancia ($\sim 1/\varpi$) sea inferior al 20%. Observacionalmente, previene la detección de fuentes ruidosas, falsos cúmulos y la difuminación del núcleo de movimiento real en el espacio de fases.

B. Modelo de Verosimilitud Bayesiana (Vasilevskis-Slovak)

Se implementó un Modelo de Mezcla Gaussiana (GMM) para modelar la distribución de probabilidad en el Vector Point Diagram (VPD). La función de verosimilitud total L , que se busca maximizar, es la suma ponderada de dos densidades de probabilidad (PDF):

$$L(\theta) = n_c \cdot \Phi_c(\mu_{\alpha*}, \mu_{\delta}) + (1 - n_c) \cdot \Phi_f(\mu_{\alpha*}, \mu_{\delta}) \quad (2)$$

Donde las variables se definen de la siguiente manera:

- n_c : Fracción poblacional de estrellas que pertenecen al cúmulo.

- Φ_c : Función de Densidad de Probabilidad (PDF) del cúmulo, asumida como una **Gaussiana Circular** isotrópica:

$$\Phi_c = \frac{1}{2\pi\sigma_c^2} \exp\left(-\frac{(\mu_{\alpha*} - \bar{\mu}_{\alpha*c})^2 + (\mu_\delta - \bar{\mu}_{\delta*c})^2}{2\sigma_c^2}\right) \quad (3)$$

- Φ_f : PDF del campo galáctico de fondo, asumida como una **Gaussiana Bivariada Elíptica** para capturar la dispersión anisotrópica inducida por la rotación diferencial galáctica:

$$\Phi_f = \frac{1}{2\pi\sigma_{fx}\sigma_{fy}\sqrt{1-\rho^2}} \exp\left(-\frac{z}{2(1-\rho^2)}\right) \quad (4)$$

Siendo z el término cuadrático estandarizado que incluye el coeficiente de correlación ρ entre los movimientos propios del fondo.

Este método busca el centroide cinemático de M41 optimizando el vector de parámetros θ usando el algoritmo L-BFGS-B. La principal limitación consiste en que las distribuciones gaussianas no se adaptan adecuadamente a las asimetrías de los cúmulos en la realidad, haciendo que el algoritmo asimile erróneamente estrellas no pertenecientes al cúmulo.

C. Clustering Topológico Basado en Densidad: HDBSCAN

El HDBSCAN (*Hierarchical Density-Based Spatial Clustering of Applications with Noise*) extrae estructuras basándose en la proximidad y número de elementos en un vecindario. La base matemática del algoritmo es la transformación del espacio original mediante la **Distancia de Alcanzabilidad Mutua** (d_{mreach}):

$$d_{\text{mreach}}(a, b) = \max\{\text{core}_k(a), \text{core}_k(b), d(a, b)\} \quad (5)$$

Donde $\text{core}_k(x)$ representa la distancia métrica desde el punto x hasta su k -ésimo vecino más cercano, y $d(a, b)$ es la métrica original (típicamente euclidiana).

Esta formulación permite que el HDBSCAN se *contraiga* y *expanda* según la densidad del cúmulo. Adicionalmente, al pasar de un espacio 2D a uno 3D usando la paralaje (ϖ), el algoritmo segrega estrellas cinemáticamente similares pero desacopladas en el eje de profundidad, dando un mejor nivel de análisis que con movimientos propios.

IV. METODOLOGÍA COMPUTACIONAL

A. GMM

El flujo de trabajo en Python utiliza las librerías **pandas** (McKinney, 2010), **numpy** (Harris et al., 2020), **scikit-learn** (Pedregosa et al., 2011), **scipy** (Virtanen et al., 2020), junto con OPTUNA (Akiba et al., 2019). Se divide el entorno en las siguientes fases:

Primeramente se filtra la serie de datos del M41 de valores nulos (NaN) en las variables cinemáticas y fotométricas. Posteriormente, se aplicó un filtro de calidad astrométrica restringiendo la muestra a fuentes con `parallax_over_error > 5`.

Teniendo en cuenta la sensibilidad de escala de los algoritmos basados en densidad, se estandarizaron las variables de entrada utilizando el transformador **RobustScaler** de **scikit-learn**. Este escalador utiliza el rango entre cuartiles, mitigando el efecto de estrellas con movimientos propios muy atípicos.

Se construyeron dos matrices de características (espacios de fases): un espacio bidimensional $X_{2D} = (\mu_{\alpha*}, \mu_\delta)$ y un espacio tridimensional $X_{3D} = (\mu_{\alpha*}, \mu_\delta, \varpi)$.

Se optimizó un Modelo de Mezcla Gaussiana (GMM) correspondiente al formalismo de Vasilevskis-Slovak. Para inicializar los centroides cinemáticos (μ_{xc}, μ_{yc}) del modelo *prior*, se generó un histograma 2D identificando el pico de máxima densidad local.

La función objetivo a minimizar fue la Verosimilitud Logarítmica Negativa (Negative Log-Likelihood), iterando sobre 9 parámetros libres (θ). Esta minimización se ejecutó empleando la función `scipy.optimize.minimize` con el algoritmo cuasi-Newton L-BFGS-B, definiendo límites topológicos estrictos (*bounds*) para evitar divergencias en la covarianza galáctica. Finalmente, se asignó la membresía a aquellas estrellas cuya probabilidad a posteriori superó el umbral empírico de $P > 0,5$ (fijado empíricamente).

B. Clustering Jerárquico por Densidad (HDBSCAN)

Se implementa el algoritmo de clasificación HDBSCAN utilizando el criterio de *Excess of Mass* (EOM) para seleccionar clústeres basados en su persistencia de magnitud al ser comparado con los demás cúmulos.

Para el análisis comparativo se realizan los siguientes escenarios:

Primeramente, para evitar el efecto de los movimientos propios en los extremos se aplicó un `RobustScaler` para que el HDBSCAN pudiera centrarse en el cúmulo. Luego se hizo un análisis en 2 modelos: modelo 2D y 3D.

- **Modelo 2D:** Se basa exclusivamente en el plano de movimientos propios ($\mu_{\alpha*}, \mu_{\delta}$), optimizado con $n_{min} = 80$ y $m_{samples} = 13$.
- **Modelo 3D:** Se le agrega el paralaje (ϖ) para añadir profundidad espacial, empleando parámetros de $n_{min} = 60$ y $m_{samples} = 10$.

Para identificar automáticamente el cúmulo M41, se seleccionó el grupo cuyo centro estuviera más cerca de las coordenadas de referencia ($\mu_{\alpha*} \approx -3,3, \mu_{\delta} \approx 5,5$ mas/yr). De lo contrario, el HDBSCAN podría seleccionar otros posibles centros para el cúmulo que no son adecuados basado únicamente en densidad. De igual manera se incluyó el gráfico con todas las asociaciones detectadas por HDBSCAN 2.¹

Para asegurar la limpieza de los datos, solo se incluyeron estrellas con una probabilidad de pertenencia mayor al 50 % ($P > 0,5$), permitiendo obtener una secuencia principal más definida en el análisis fotométrico.

V. RESULTADOS Y ANÁLISIS

El procesamiento de los datos de Gaia DR3 para la región de M41 permitió contrastar cinco aproximaciones de clasificación. A continuación se discuten los resultados de morfología y calidad de pertenencia en la Figura 1.

A. Modelo Bayesiano

El ajuste mediante el modelo de Vasilevskis-Slovak (GMM de dos componentes) identificó un total de $N = 877$ candidatos a miembros. A pesar de detectar el centroide cinemático en $\mu_{\alpha*} \approx -3,3$ y $\mu_{\delta} \approx 5,5$ mas yr⁻¹, el Vector Point Diagram (VPD) revela una dispersión excesiva. La naturaleza gaussiana del modelo incluye ruido de fondo galáctico, lo que se traduce en un Diagrama Color-Magnitud (CMD) con una secuencia principal altamente contaminada por estrellas de campo, quitando definición en la isocrona.

B. Análisis de Clustering Topológico (HDBSCAN 2D)

La aplicación de HDBSCAN en el plano de movimientos propios mostró una alta sensibilidad a los hiperparámetros:

- **Modelo Base** ($sz = 30, sam = 10$): Resultó excesivamente restrictivo ($N = 40$), capturando solo el núcleo más denso y perdiendo la continuidad estructural del cúmulo.
- **Modelo Manual** ($sz = 80, sam = 13$): Se evidencia *over-clustering* masivo ($N = 1996$). Al ignorar la dimensión de profundidad (paralaje), el algoritmo agrupó erróneamente variaciones en la densidad del campo galáctico que comparten vectores de velocidad similares, lo que produce un CMD que no concuerda con la astrofísica esperada para M41 dada su morfología ya estudiada.

C. HDBSCAN 3D

El modelo **HDBSCAN 3D (Manual: $sz = 60$)** permitió los mejores resultados (verificado por el CMD), aislando $N = 111$ estrellas con una alta probabilidad de membresía. Se puede apreciar un núcleo comparco en el VPD al igual que una S.P estrecha y bien definida, confirmando que el agregar el paralaje ayudó a eliminar estrellas no pertenecientes (*interpolers* en inglés) que estaban en frente o detrás del M41.

Es necesario recalcar que la fidelidad de estos métodos requiere de un contraste con la literatura conocida. Como se puede observar en la Figura. 2, HDBSCAN presenta un análisis jerárquico que requiere de un refinamiento, ya sea suministrado por la literatura o por otras herramientas computacionales cuyos resultados sean astronómicamente adecuados.

Se piensa que las asociaciones azules o moradas pueden ser asociaciones estelares jóvenes o grupos en movimiento no ligados. Nótese que a pesar de tener varias asociaciones, la extensión y densidad del cúmulo cambia radicalmente al introducir el paralaje en el análisis 3D 2.

¹ Es importante limitar o guiar a los algoritmos según los parámetros físicos ya conocidos a menos que haya una buena razón para no hacerlo. Otro ejemplo de esto es en el tamaño mínimo de un cúmulo, aunque la literatura establece un rango entre 100 y 10000, el algoritmo necesita un umbral menor.²




Figura 1. Panel comparativo de la selección astrométrica de miembros para el cúmulo abierto M41 utilizando datos de la misión Gaia DR3. La cuadrícula de 5x2 presenta en la columna izquierda los Diagramas de Movimiento Propio o *Vector Point Diagrams* (VPD) en el espacio de fases tangencial ($\mu_{\alpha*}$ vs. μ_{δ} en mas/yr). En la columna derecha se muestran los respectivos Diagramas Color-Magnitud (CMD) en el plano observacional ($G_{BP} - G_{RP}$ vs. G). De arriba hacia abajo, las filas exponen los resultados de cinco configuraciones algorítmicas: (1) Modelo probabilístico Bayesiano con un corte de selección $P > 0,5$; (2) Clustering topológico HDBSCAN en 2D ($\mu_{\alpha*}, \mu_{\delta}$) con parámetros base (`min_cluster_size=30`, `min_samples=10`); (3) HDBSCAN en 2D con hiperparámetros manuales (`sz=80`, `sam=13`); (4) HDBSCAN en 3D (incluyendo la paralaje ϖ) con parámetros base (`sz=30`, `sam=10`); y (5) HDBSCAN en 3D con hiperparámetros manuales (`sz=60`, `sam=10`). En todos los subpaneles, la distribución general de las estrellas de campo en la línea de visión se ilustra mediante una malla de densidad en escala de grises de fondo. Los candidatos a miembros del cúmulo extraídos por cada respectivo modelo se superponen como puntos dispersos coloreados, utilizando una escala cromática (tipo *viridis*) para representar las métricas de probabilidad de membresía asignadas por el algoritmo. El conteo total de estrellas retenidas (N) para cada escenario se detalla en las leyendas superiores derechas.




Figura 2. Distribución de los candidatos a cúmulos identificados por HDBSCAN en el plano de movimientos propios (VPD, izquierda) y el diagrama color-magnitud (CMD, derecha) previo a la etapa de selección. Cada color representa un grupo de estrellas detectado por HDBSCAN que persiste al hacer el barrido de densidades. Se observa que el algoritmo identifica múltiples sobredensidades en el disco galáctico local; sin embargo, solo una de ellas (en amarillo/verde) presenta una secuencia principal (MS) definida y estrecha en el CMD que coincide con las coordenadas de referencia de M41 ($\mu_{\alpha*} \approx -3,3$, $\mu_{\delta} \approx 5,5$ mas/yr) marcada con una estrella roja.

VI. CONCLUSIONES

Se evidencia la superioridad del algoritmo HDBSCAN para asignar pertenencia de acuerdo a densidad en comparación con el GMM (N=877 bayesianos comparados a los N=111 del HDBSCAN); no obstante, se reconoce la sensibilidad de los hiperparámetros al igual que el aumento en el tiempo de procesamiento computacional. Esto puede ser la diferencia entre un sobre-filtrado, resultando en muchos menos miembros de lo que se espera, o un *over clustering* con muchas estrellas no perteneciente (como muestra el modelo 3D manual con N=1996).

Así mismo, fue crucial el aplicar un umbral inicial

según la relación Señal-Ruido sobre el paralaje mayor a 5, evitando la inclusión de fuentes adicionales y evitando la difusión del centroide del M41.

De igual importancia, se concluyó que el tener en cuenta una tercera dimensión (paralaje) hace que el modelo sea mucho mejor filtrando estrellas distantes de la secuencia principal por medio de la verificación *manual* del CMD. Agregando el valor del observador para ajustar los hiperparámetros según la astrofísica correspondiente.

A continuación se adjunta el enlace al repositorio con el código: <https://github.com/SV15641564/Astro-ML>.

-
- [1] Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). *Optuna: A next-generation hyperparameter optimization framework*. Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, 2623-2631.
 - [2] Campello, R. J. G. B., Moulavi, D., & Sander, J. (2013). *Density-based clustering based on hierarchical density estimates*. En Advances in Knowledge Discovery and Data Mining (pp. 160-172). Springer.
 - [3] Ester, M., Kriegel, H. P., Sander, J., & Xu, X. (1996). *A density-based algorithm for discovering clusters in large spatial databases with noise*. Proceedings of the Second International Conference on Knowledge Discovery and Data Mining (KDD-96), 226-231.
 - [4] Gaia Collaboration, Vallenari, A., Brown, A. G. A., Prusti, T., de Bruijne, J. H. J., Arenou, F., ... & Zwitter, T. (2023). *Gaia Data Release 3. Summary of the content and survey properties*. Astronomy & Astrophysics, 674, A1.
 - [5] Harris, C. R., Millman, K. J., van der Walt, S. J., Gommers, R., Virtanen, P., Cournapeau, D., ... & Oliphant, T. E. (2020). *Array programming with NumPy*. Nature, 585(7825), 357-362.
 - [6] McKinney, W. (2010). *Data structures for statistical computing in python*. Proceedings of the 9th Python in Science Conference, 445, 51-56.
 - [7] Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, E. (2011). *Scikit-learn: Machine learning in Python*. Journal of Machine Learning Research, 12, 2825-2830.
 - [8] Rousseeuw, P. J. (1987). *Silhouettes: A graphical aid to the interpretation and validation of cluster analysis*. Journal of Computational and Applied Mathematics, 20, 53-65.
 - [9] Vasilevskis, S., Klemola, A., & Preston, G. (1958). *Relative proper motions of stars in the region of the open cluster NGC 2281*. The Astronomical Journal, 63, 387-395.
 - [10] Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., ... & Van Mulbregt, P. (2020). *SciPy 1.0: fundamental algorithms for scientific computing in Python*. Nature Methods, 17, 261-272.